

Lineær regresjon

Mengdetrening · 4 nivåer · 36 oppgaver

Mild	Grunnleggende oppgaver
Medium	Standardoppgaver og kombinasjoner
Spicy	Sammensatte og utvidede oppgaver
Hot	Tekstoppgaver, bevis og utfordringer

Hva er lineær regresjon?

Lineær regresjon finner den rette linjen som best beskriver sammenhengen mellom to variabler. Vi minimerer summen av kvadratene av avvikene (minste kvadraters metode). Korrelasjonskoeffisienten r måler lineær sammenheng.

Nøkkelformler

Regresjonslinjen: $\hat{y} = ax + b$ der $a = S_{xy}/S_{xx}$ og $b = -a$

Korrelasjon: $r = S_{xy} / \sqrt{(S_{xx} \cdot S_{yy})}$ (r mellom -1 og $+1$)

r nær ± 1 : sterk lineær sammenheng. r nær 0 : ingen lineær sammenheng.

Determinasjonskoeffisient: $R^2 = r^2$ (andel forklart varians)

Mild

9 oppgaver

1.

Hva betyr $r=0,95$? Og $r=-0,3$?

Svar:

2.

Data: $(1,3), (2,5), (3,7), (4,9)$. Finn regresjonslinjen for hånd.

Svar:

3.

Er dette positiv eller negativ korrelasjon? a) Mer trening bedre helse b) Mer røyk kortere liv

Svar:

4.

Tegn et spredningsplot for: $(2,4), (4,7), (6,9), (8,12)$. Ser det lineært ut?

Svar:

5.

Regresjonslinjen er $\hat{y} = 2x + 1$. Prediker $\hat{y}$ for $x=5$ og $x=10$.

Svar:

6.

Hva er residualen for punktet $(3,8)$ på linja $\hat{y}=2x+1$?

Svar:

7.

Hvilken r -verdi indikerer sterkest lineær sammenheng? a) $r=0,7$ b) $r=-0,9$ c) $r=0,5$

Svar:

8.

Forklar hva "minste kvadraters metode" betyr.

Svar:

9.

Data: $(0,2), (1,4), (2,6), (3,8)$. Er $r=1$? Begrunn.

Svar:

Medium

9 oppgaver

10.

Data: $x=[1,2,3,4,5]$, $y=[2,4,5,4,5]$. Beregn $\bar{x}$, S_{xx} , S_{xy} og regresjonslinjen.

Svar:

11.

$r=0,75$, $n=20$. Er sammenhengen statistisk signifikant (kritisk $r \approx 0,44$)?

Svar:

12.

Regresjonslinje $y=3x+2$. Faktisk $y=20$ ved $x=5$. Beregn residualet.

Svar:

13.

Hva er R^2 for $r=0,85$? Hva betyr det?

Svar:

14.

Ekstrapolasjon: $\hat{y}=2,5x+10$. Data fra $x=5$ til 30. Er prediksjon for $x=100$ pålitelig?

Svar:

15.

To variabler: antall TV-timer/dag og testresultat. $r = -0,62$. Tolk.

Svar:

16.

Data for høyde (x) og vekt (y): $(165,60), (170,70), (175,75), (180,85)$. Finn regresjonslinjen og prediker vekt for 168 cm.

Svar:

17.

Hva er problemet med å bruke regresjon til å si at x forårsaker y ?

Svar:

18.

Outlier-effekt: Forklar hvordan ett avvikende punkt kan ødelegge en regresjonslinje.

Svar:

Spicy

9 oppgaver

HuskelappRegresjonslinjen: $\hat{y} = ax + b$ der $a = S_{xy}/S_{xx}$ og $b = -a$ Korrelasjon: $r = S_{xy} / \sqrt{(S_{xx} \cdot S_{yy})}$ (r mellom -1 og +1)**19.**Regresjonslikninger: $\hat{y} = 0,8x + 2$, $R^2 = 0,64$. Beregn r og tolk.

Svar:

20.Transformasjon: Data følger $y=a \cdot b$. Ta ln på begge sider. Hvordan tilpasser du lineær regresjon?

Svar:

21.Multippel regresjon: $\hat{y} = 2x + 3x + 5$. Prediker $\hat{y}$ for $x=4$, $x=2$.

Svar:

22.

Heteroskedastisitet: Hva er det og hvordan oppdager du det i et residualplot?

Svar:

23.Finn regresjonslinjen for: $(-2,1), (0,3), (1,4), (3,7), (5,9)$.

Svar:

24.Kalibrering: et instrument leser x , sann verdi y . Regresjon gir $\hat{y}=1,02x-0,5$. Korriger en måling på $x=10$.

Svar:

25.

Pearson vs Spearman korrelasjon: Forklar forskjellen.

Svar:

26.Data: temperaturer og isdraktsalg. $r=0,92$. Forklar om dette er kausalitet.

Svar:

27.

Kryssvalidering: Hva er det og hvorfor er det viktig?

Svar:

Hot

9 oppgaver

HuskelappRegresjonslinjen: $\hat{y} = ax + b$ der $a = S_{xy}/S_{xx}$ og $b = -a$ Korrelasjon: $r = S_{xy} / \sqrt{(S_{xx} \cdot S_{yy})}$ (r mellom -1 og +1)**28.**

Normallikninger: Utled a og b i $\hat{y} = ax + b$ ved å minimere $(y - ax - b)^2$. Bruk partiell derivasjon.

Svar:

29.

Anscombe: Anscombes kvartett: fire datasett med nesten identisk regresjon men helt ulike mønstre. Beskriv.

Svar:

30.

Lasso vs Ridge: Forklar regularisering i regresjon.

Svar:

31.Forklart varians: Vis at $SST = SSR + SSE$.

Svar:

32.

Konfidensintervall for prediksjon: Forklar forskjellen på KI for gjennomsnitt og KI for enkelt observasjon.

Svar:

33.

Logistisk regresjon: Hva er den, og når brukes den fremfor lineær regresjon?

Svar:

34.Simpsons paradoks: Gi et eksempel der r er positiv i to grupper men negativ i totaldatasettet.

Svar:

35.

Tidsserie: Hva er autokorrelasjon og hvordan bryter det forutsetningene for vanlig regresjon?

Svar:

36.

Utfordring: Designet et eksperiment for å teste om regresjon kan predikere eksamensscore fra studietid. Beskriv alt: utvalg, design, analyse, tolkning og etikk.

Svar:

Fullstendig fasit

Vis alltid fremgangsmåten — riktig svar uten utregning gir ikke full uttelling.

Mild

Nr	Svar / Fremgangsmåte
1	$r=0,95$: sterk positiv lineær sammenheng. $r=-0,3$: svak negativ.
2	$x=2,5$, $y=6$. $S_{xy}=5$, $S_{xx}=5/2=2,5$. $a=2$, $b=6-5=1$. Linje: $y=2x+1$
3	a) Positiv b) Negativ
4	Ser lineært ut (stiger jevnt)
5	$x=5$: 11. $x=10$: 21
6	$\hat{y}=7$. Residual= $8-7=1$
7	b) $r=-0,9$ (sterkest, nær -1)
8	Minimer $(y-\hat{y})^2$: vi finner linjen der summen av kvadrerte loddrett-avvik er minst
9	Ja, $r=1$. Alle punkter er nøyaktig på linja $y=2x+2$

Medium

Nr	Svar / Fremgangsmåte
10	$x=3$, $y=4$. $S_{xx}=10$, $S_{xy}=7$. $a=0,7$, $b=4-2,1=1,9$. $\hat{y}=0,7x+1,9$
11	$r=0,75 > 0,44$ signifikant sammenheng
12	$\hat{y}=17$. Residual= $20-17=3$
13	$R^2=0,7225$. 72,25% av variansen forklart av x
14	Nei – ekstrapolasjon langt utenfor dataområdet er upålitelig
15	Moderat negativ sammenheng. Mer TV-tid noe lavere testresultat (men ikke kausalitet)
16	$k \approx 1,67$, $b \approx -215$. For 168 cm: $\hat{y} \approx 65$ kg
17	Korrelasjon $\neq$ kausalitet. Konfunderende variabler kan forklare begge
18	Outlier kan rotere linja dramatisk og øke/reducere a-koeffisienten

Spicy

Nr	Svar / Fremgangsmåte
19	$r = \sqrt{0,64} = 0,8$. Moderat sterk positiv lineær sammenheng
20	$\ln(y) = \ln(a) + x \cdot \ln(b)$. La $Y = \ln(y)$, $B = \ln(b)$, $A = \ln(a)$: $Y = Bx + A$ lineær regresjon på $(x, \ln(y))$
21	$\hat{y} = 8 + 6 + 5 = 19$
22	Heteroskedastisitet: varians i residualene øker/minker med x. Trakt-form i residualplot.
23	$x = 1,4$, $y = 4,8$. $S_{xy} = 16,2$, $S_{xx} = 22,8$... $a \approx 0,72$... $\hat{y} \approx 0,72x + 3,79$... (ca $y = 0,7x + 3,8$)
24	$y = 1,02 \times 10 - 0,5 = 9,7$
25	Pearson: lineær sammenheng av tall. Spearman: rangkorrelasjon, robust mot outliers og ikke-linearitet
26	Trolig kausalitet (varmt vær mer is), men sammenhengen er indirekte via temperatur
27	Trene på del av data, teste på resten – sjekker om modellen generaliserer

Hot

Nr	Svar / Fremgangsmåte
28	$\partial/\partial a (y - ax - b)^2 = 0$ $x(y - ax - b) = 0$ $S_{xy} = a \cdot S_{xx}$. $\partial/\partial b = 0$ $= a + b$
29	Alle fire: $x = 9$, $y = 7,5$, $r \approx 0,816$. Men: 1 lineær, 2 kvadratisk, 3 med outlier, 4 vertikal kluster
30	Lasso: L1-regularisering, gir sparsitet. Ridge: L2, reduserer koeffisienter jevnt. Begge hindrer overfitting.
31	$SST = (y - \bar{y})^2$. $SSR = (\hat{y} - \bar{y})^2$. $SSE = (y - \hat{y})^2$. $SST = SSR + SSE$ ved utledning av normallikningene.
32	KI for gjennomsnitt: smalere (estimerer populasjonsgjennomsnittet). KI for enkelt obs: bredere (inkluderer residualvarians).
33	Logistisk: binær utfallsvariabel (0/1). Modellerer sannsynlighet via sigmoid-funksjon.
34	Eks: universitetssøkere – kvinner godtas mer i hard vitenskap, menn i humaniora, men totalt godtas menn mer pga. søksmønster
35	Autokorrelasjon: residualene er avhengige av hverandre over tid. Bryter OLS-forutsetningen om uavhengige feil.
36	Utvalg: tilfeldig fra klasse. Design: mål studietimer og karakter. Analyse: regresjon + R^2 + p-verdi. Etikk: anonymisere data.