

Statistikk fra ekte data

Mengdetrening · 4 nivåer · 36 oppgaver

Mild	Grunnleggende oppgaver
Medium	Standardoppgaver og kombinasjoner
Spicy	Sammensatte og utvidede oppgaver
Hot	Tekstoppgaver, bevis og utfordringer

Å jobbe med virkelige data

Ekte data er rotete, ufullstendige og overraskende. Vi må rense, beskrive og tolke data kritisk. Deskriptiv statistikk gir oversikt. Inferensiell statistikk trekker slutninger til populasjonen basert på et utvalg.

Viktige mål

Sentralmål: gjennomsnitt ($\bar{x}$), median (Q_2), typetall (modus)

Spredningsmål: rekkevidde, $IQR=Q_3-Q_1$, standardavvik (s), varians (s^2)

Standardavvik: $s = \sqrt{((x-\bar{x})^2)/(n-1)}$

Outlier-regel: utenfor $Q_1-1,5 \times IQR$ eller $Q_3+1,5 \times IQR$

Mild

9 oppgaver

1.

Data: 12, 15, 11, 18, 14, 15, 13. Finn gjennomsnitt, median og typetall.

Svar:

2.

Data: 4, 7, 9, 12, 14, 18, 20. Finn Q1, Q2 (median) og Q3.

Svar:

3.

Rekkevidde og IQR for: 3, 8, 12, 14, 19, 25, 30.

Svar:

4.

Finn standardavvik for: 2, 4, 4, 4, 5, 5, 7, 9.

Svar:

5.

Et datasett har gjennomsnitt 50 og standardavvik 5. Er 65 en outlier?

Svar:

6.

Lag et boksplott for: 5, 8, 10, 12, 14, 16, 20, 25.

Svar:

7.

Hva er de beste sentralmålene for skjeve data (med outliere)?

Svar:

8.

Data for alder i en klasse ($n=25$): min=13, $Q1=14$, median=15, $Q3=16$, maks=17. Tegn boksplott.

Svar:

9.

En dataenhet på 200 er med i datasettet $\{5,8,10,12,15\}$. Hva skjer med gjennomsnitt og median?

Svar:

Medium

9 oppgaver

10.

Frekvenstabellen: {1:3, 2:5, 3:4, 4:2, 5:1}. Finn gjennomsnitt, median og typetall.

Svar:

11.

Finn outliergrensene for datasettet: 10,20,30,40,50,60,200.

Svar:

12.Sammenlign spredning: Datasett A ($s=10$) vs Datasett B ($s=2$). Begge har $x=50$.

Svar:

13.Normalfordeling: $\mu=100$, $\sigma=15$ (IQ). Finn prosent mellom 85 og 115.

Svar:

14.

Histogrammet er skjev til høyre. Hvilken er størst: gjennomsnitt eller median?

Svar:

15.

Kovarians og korrelasjon: Hva er forskjellen?

Svar:

16.

Ti karakterer: 3,4,4,5,5,5,6,6,6,6. Beregn standardavvik.

Svar:

17.

Sammenliknende boksplott: Gruppe A: min=10,Q1=20,med=30,Q3=40,maks=50. Gruppe B: min=5,Q1=15,med=25,Q3=50,maks=80. Hvilken er mest spredt?

Svar:

18.Z-score: $z = (x - \mu) / \sigma$. Finn z-score for $x=130$, $\mu=100$, $\sigma=15$.

Svar:

Spicy

9 oppgaver

HuskelappSentralt mål: gjennomsnitt ($\bar{x}$), median (Q_2), typetall (modus)Spredningsmål: rekkevidde, $IQR=Q_3-Q_1$, standardavvik (s), varians (s^2)**19.**Et datasett på 12 verdier: $x=40$, $x^2=20200$. Finn variansen s^2 .

Svar:

20.To normalfordelte datasett: $\mu=70, \sigma=10$ og $\mu=80, \sigma=5$. Overlappsjanser?

Svar:

21.

Percentil: En student scorer 85 og er i 90. percentil. Forklar hva det betyr.

Svar:

22.Datasettet: lønn for 8 ansatte (i tusen): 35,38,40,42,45,48,50,200. Er 200 en outlier? Bruk $1,5 \times IQR$ -regelen.

Svar:

23.

Standardiseringsfeil: Hva er galt med å sammenligne z-scorer fra to ulike normalfordelinger?

Svar:

24.

Design et boksplott-sammenligning for å svare: "Er gutter eller jenter mer sporty i klassen?"

Svar:

25.

Finn 95. percentil for normalfordelingen $\mu=500$, $\sigma=100$ ($z=1,645$).

Svar:

26.

Varsians-addisjon: $\text{Var}(X+Y)=\text{Var}(X)+\text{Var}(Y)$ for uavhengige. $\text{Var}(3X)=9\text{Var}(X)$. Bruk på $\text{Var}(2X+Y)$.

Svar:

27.

Binomial: $X \sim B(10, 0,3)$. Finn $P(X=3)$ og $E(X)$.

Svar:

Hot

9 oppgaver

HuskelappSentralmål: gjennomsnitt ($\bar{x}$), median (Q_2), typetall (modus)Spredningsmål: rekkevidde, $IQR=Q_3-Q_1$, standardavvik (s), varians (s^2)**28.**

CLT: Sentralgrenseteoremet: $\bar{x}$ fra $n=50$ er tilnærmet normalfordelt selv om populasjonen er skjev. Demonstrer med intuisjon.

Svar:

29.

t-test: To grupper: $\bar{x}=52$, $s=8$, $n=30$ og $\bar{x}=48$, $s=10$, $n=30$. $t=(\bar{x}_1-\bar{x}_2)/SE_{diff}$. Er forskjellen signifikant?

Svar:

30.

ANOVA: Tre grupper. Forklar hva ANOVA tester og hva F-statistikken måler.

Svar:

31.

Bootstrapping: Forklar prinsippet og når det er nyttig.

Svar:

32.Effektstørrelse: Cohen's $d=0,2$ (liten), $0,5$ (medium), $0,8$ (stor). Beregn d for $x=75$, $x=70$, $s=10$.

Svar:

33.

Tidsserie: CO-data 1958–2023 viser stigende trend. Beskriv en komplett statistisk analyse.

Svar:

34.Bayesiansk oppdatering: Prior: $P(\text{regn})=0,3$. Barometeret faller ($P(\text{fall}|\text{regn})=0,7$, $P(\text{fall}|\text{ikke regn})=0,2$). Finn posterior $P(\text{regn}|\text{fall})$.

Svar:

35.

Kausalinferens: Difference-in-differences-metoden – forklar og gi et eksempel.

Svar:

36.

Utfordring: Design en fullstendig statistisk studie for å teste om lekser gir bedre karakterer. Inkluder alle faser.

Svar:

Fullstendig fasit

Vis alltid fremgangsmåten — riktig svar uten utregning gir ikke full uttelling.

Mild

Nr	Svar / Fremgangsmåte
1	$x=14$. Median=14. Typetall=15
2	$Q1=7$, $Q2=12$, $Q3=18$
3	Rekkevidde=27. $IQR=19-8=11$
4	$x=5$. $(x-5)^2=16$. $s=\sqrt{(16/7)}\approx 1,51$
5	$z=(65-50)/5=3$. 3 std. fra gjennomsnittet ja, trolig outlier
6	min=5, $Q1=9$, med=13, $Q3=18$, maks=25. Tegnet korrekt
7	Median og IQR er robuste mot outliere
8	Tegnet korrekt med horisontal boks fra 14 til 16, strek ved 15, whiskers til 13 og 17
9	Gjennomsnitt øker dramatisk. Median endres minimalt (fra 10 til 11).

Medium

Nr	Svar / Fremgangsmåte
10	$x=(3+10+12+8+5)/15=38/15\approx 2,53$. Median=2. Typetall=2
11	$Q1=20$, $Q3=60$, $IQR=40$. Grenser: $20-60=-40$ og $60+60=120$. $200>120$ outlier
12	A er mye mer spredt (10 vs 2 i standardavvik). B er mer konsentrert rundt gjennomsnittet.
13	68% innenfor ± 1
14	Gjennomsnitt er størst ved høyreskjev fordeling (dratt mot høyre av høye verdier)
15	Kovarians: absolutt mål på samvariasjon. Korrelasjon: standardisert (-1 til 1), sammenlignbar.
16	$x=5$. $(x-5)^2=4$. $s=\sqrt{(4/9)}\approx 0,67$
17	Gruppe B er mer spredt (bredere boks, lengre whisker og outliere)
18	$z=(130-100)/15=2$

Spicy

Nr	Svar / Fremgangsmåte
19	$s^2 = (x^2 - nx^2) / (n-1) = (20200 - 12 \times 1600) / 11 = (20200 - 19200) / 11 \approx 90,9$
20	Overlapp er størst rundt $\mu - 2 = 70$. Grafisk: to normalfordelinger med visst overlapp
21	85% av alle scorer er lavere enn 85
22	$Q1 = 39$, $Q3 = 49$, $IQR = 10$. Grense $= 49 + 15 = 64$. $200 > 64$ outlier
23	Z-scorer er kun sammenlignbare innen samme fordeling. Ulike μ og gjør direkte sammenligning meningsløs.
24	Samle treningstid/aktivitetsskåre for begge kjønn. Tegn boksplott side om side. Sammenlign median og IQR.
25	$x = 500 + 1,645 \times 100 = 664,5$
26	$\text{Var}(2X + Y) = 4\text{Var}(X) + \text{Var}(Y)$
27	$P(X=3) = C(10,3) \times 0,3^3 \times 0,7 \approx 0,267$. $E(X) = np = 3$

Hot

Nr	Svar / Fremgangsmåte
28	Mange terningkast: summen av ulike fordelinger klokkeform. CLT: uavhengig av fordeling for stor n.
29	$SE = \sqrt{(64/30 + 100/30)} = \sqrt{(5,47)} \approx 2,34$. $t = (52 - 48) / 2,34 \approx 1,71$. Grense $\approx 2,0$. Ikke signifikant.
30	ANOVA: Tester om minst én gruppe har annerledes gjennomsnitt. $F = \text{mellomgruppevarians} / \text{innengruppevarians}$.
31	Bootstrapping: resample med tilbakelegging mange ganger, bygg fordelingen til en estimator. Nyttig ved ukjent fordeling.
32	$d = (75 - 70) / 10 = 0,5$ (medium effektstørrelse)
33	Beskriv: tidsserie-plot, dekomponering (trend+sesong), regresjonsmodell, residualanalyse, konfidensintervall for stigning.
34	$P(\text{regn} \text{fall}) = (0,7 \times 0,3) / (0,7 \times 0,3 + 0,2 \times 0,7) = 0,21 / 0,35 = 0,6$
35	DiD: sammenlign endring over tid mellom behandlings- og kontrollgruppe. Eks: minimumslønnsøkning i én stat vs nabostaten.
36	Randomiser klasser (behandling/kontroll). Mål karakterer pre/post. Bruk t-test eller DiD. Kontroller for konfundere.